

Análise do Dataset Water Meters

(Kaggle)

Trabalho da Disciplina de Tópicos Especiais em IA

Estudantes: Anderson Oliveira, Bárbara Talita, Jeovane Santos, Quele Andrade, Ricardo Teixeira

Orientador: Dr. Tiago Pagano

Curso: Bacharelado em Engenharia de Computação

16 de dezembro de 2024

Sumário

- 1 Resumo
- 2 Introdução
 - Contextualização
 - Justificativa
 - Objetivo
- 3 Metodologia
 - Análise do Dataset
- Pré-Processamento
- Arquitetura do Modelo
- 4 Resultados esperados
- 5 Resultados Parciais
 - Loss
 - Métrica MAE
 - Predição
- 6 Considerações finais

Resumo

Este projeto apresenta modelo de aprendizado profundo para a detecção e segmentação de hidrômetros em imagens. Utilizando o dataset "Water Meters Dataset" do Kaggle, composto por 1244 imagens e máscaras segmentadas, implementamos este modelo baseado na arquitetura InceptionV3 pré-treinada.

Palavras-Chave: Detecção de hidrômetros; Segmentação de imagens; Regressão de coordenadas; InceptionV3.

Contextualização

- A aplicação de redes neurais convolucionais (CNNs) em tarefas de visão computacional, como a detecção de objetos, tem se mostrado altamente eficaz. Estudos demonstram que CNNs são capazes de identificar e localizar objetos em imagens com precisão significativa, mesmo em condições desafiadoras [1].
- A leitura manual de hidrômetros é um processo demorado e sujeito a erros, especialmente em condições adversas [2].
- Automatizar a leitura de hidrômetros, reduz erros manuais e aumentando a eficiência, com impacto direto na otimização de recursos e na gestão inteligente do consumo de água [3].

Justificativa

- A leitura manual de hidrômetros enfrenta erros humanos e desafios causados por fatores como iluminação inadequada e reflexos.
- A automação com aprendizado profundo e visão computacional permite realizar a leitura com maior precisão e eficiência.
- A automação reduz erros, possibilita monitoramento em tempo real e torna o processo de medição mais ágil.
- O uso de tecnologias avançadas contribui para uma gestão sustentável e consciente dos recursos hídricos.

Objetivo

Desenvolver um modelo de visão computacional baseado em técnicas de inteligência artificial avançada para detectar e localizar hidrômetros em imagens, utilizando redes neurais convolucionais e técnicas de regressão, com o objetivo de explorar os fundamentos de inteligência artificial aplicados a problemas reais.

Metodologia

A metodologia está dividida em três etapas principais:

- **Análise do Dataset:** Estudo das características e classes do conjunto de dados.
- **Pré-Processamento:** Preparação dos dados, incluindo redimensionamento, normalização e separação para treino, validação e teste.
- **Arquitetura do Modelo:** Definição do modelo de rede neural, utilizando um modelo pré-treinado e ajustado para a tarefa.

Metodologia: Análise do Dataset

- O dataset utilizado é o YandexToloka Water Meters Dataset, disponível no Kaggle.
- Link: <https://www.kaggle.com/datasets/tapakah68/yandextoloka-water-meters-dataset>
- O objetivo do dataset é a detecção e localização de hidrômetros em imagens.
- Número total de imagens: 1244.
- As imagens variam em termos de ângulo, iluminação e obstrução.

Metodologia: Análise do Dataset

- O conjunto de dados inclui 3 pastas:
 - Colagem: Imagens de hidrômetros com caixas delimitadoras.
 - Imagens: Imagens originais de hidrômetros.
 - Máscaras: Máscaras de segmentação para as imagens.
- O arquivo '.csv' inclui as seguintes informações:
 - Nome da imagem.
 - Valor do hidrômetro.
 - Localização da caixa delimitadora.

Metodologia: Análise do Dataset

Imagem 1



Imagem 2



Imagem 3



Imagem 4



Imagem 5



Figura 1: Exemplos de imagens do dataset YandexToloka Water Meters, apresentando variações de ângulo, iluminação e obstruções. Fonte: Kucev Roman, 2019, Kaggle

Metodologia: Pré-Processamento

- Redimensionamento das Imagens para 299x299.
- Normalização de pixels para valores entre 0 e 1.
- Padronização de Pontos de Interesse.
- Separação do dataset em treino, validação e teste.



Metodologia: Arquitetura do Modelo

- Base do modelo:
 - Rede pré-treinada: InceptionV3.
 - Camadas congeladas inicialmente para preservar pesos aprendidos.
- Ajustes para regressão:
 - Camadas adicionais:
 - *GlobalAveragePooling2D* para reduzir dimensionalidade.
 - Camada densa (*Dense layer*) para prever coordenadas de referência.
 - Saída ajustada para prever coordenadas (x_{\min} , y_{\min} , x_{\max} , y_{\max}).

Metodologia: Arquitetura do Modelo

- Configuração de treinamento:
 - Otimizador: Adam.
 - Função de perda: Mean Squared Error (MSE).
 - Métrica de avaliação: Mean Absolute Error (MAE).
- Modelos desenvolvidos:
 - Modelo com 2 pontos: Previsão da localização de 2 pares ordenados (ponto superior direito e ponto inferior esquerdo).
 - Modelo com 8 pontos: Previsão de 8 pares ordenados para bordas mais detalhadas do hidrômetro.
- Técnica de ajuste fino:
 - Descongelamento de 100 camadas da base para *fine-tuning*.
 - Uso de *callback* ReduceLROnPlateau para ajustar a taxa de aprendizado dinamicamente.

Resultados esperados

Os resultados esperados são a forma concreta para alcançar os objetivos do projeto, portanto deve existir uma correspondência estreita entre esses aspectos.

- Identificação eficiente dos hidrômetros nas imagens.
- Melhor desempenho de modelo com base nas métricas de avaliação.
- Geração de um pipeline robusto e aplicável a diferentes cenários.

Resultados esperados

A continuidade do desenvolvimento do modelo visa a obtenção de resultados que:

- Proporcionem precisão e desempenho otimizado para a tarefa de detecção.
- Permitirão a adaptação do modelo a novos conjuntos de dados de hidrômetros.
- Resultem em um modelo capaz de generalizar bem para diferentes condições de imagem.

Resultados Parciais




Figura 2: Gráfico da função de perda (*loss*) ao longo das épocas, indicando a convergência do modelo durante o treinamento.

Resultados Parciais

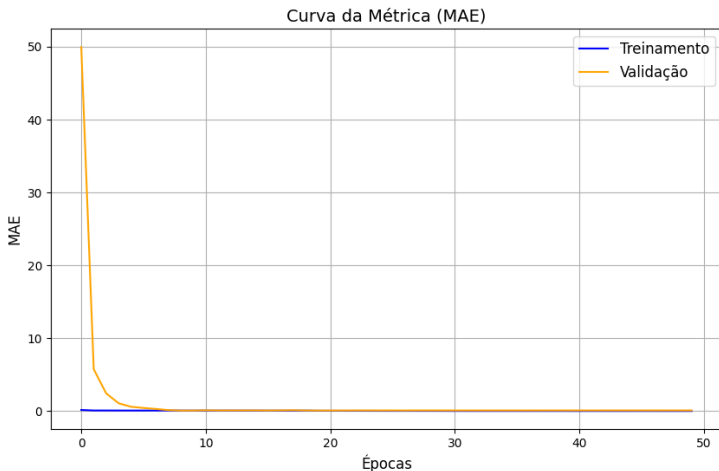


Figura 3: Evolução da métrica *Mean Absolute Error* (MAE) ao longo do treinamento, demonstrando melhorias na precisão das predições do modelo.

Resultados Parciais


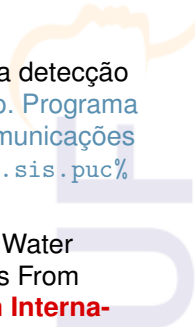


Figura 4: Exemplo de predição gerada pelo modelo, com coordenadas previstas sobrepostas à imagem original do hidrômetro (*bounding box*).

Considerações Finais

- O modelo desenvolvido, baseado na arquitetura InceptionV3, demonstrou resultados promissores na tarefa de detecção e localização de hidrômetros.
- Métricas como **loss** e **MAE** indicaram que o modelo está aprendendo de forma consistente e aprimorando sua capacidade de previsão.
- Limitações como variações extremas de iluminação ainda representam desafios, mas podem ser mitigadas com ajustes no treinamento e na coleta de dados.
- Este trabalho reforça a aplicabilidade de técnicas de aprendizado profundo na automação de tarefas complexas, como a leitura de hidrômetros.
- Futuras melhorias incluem:
 - Avaliação do modelo em datasets mais variados;
 - Implementação de técnicas adicionais de fine-tuning.

Referências I

- 
- [1] Bruno Romão. “Redes neurais convolucionais para a detecção de objetos”. Acesso aberto. Dissertação de Mestrado. Programa de Pós-Graduação em Gestão de Redes de Telecomunicações (PPGRT), abr. de 2023. URL: <https://repositorio.sis.puc%20campinas.edu.br/handle/123456789/16933>.
- [2] Nattanon Saetan e Kwankamon Dittakan. “Thailand Water Meter Reading Using Convolutional Neural Networks From Smartphone Imagery”. Em: **Proceedings of the 9th International Conference on Digital Arts, Media, and Technology (DAMT) and the 7th ECTI Northern Section Conference on Electrical, Electronics, Computer and Telecommunications Engineering (NCON)**. Thailand, 2024.

Referências II

- [3] Yuhao Shen, Xiangqian Wang e Minghong Yin. “Reconhecimento de leitura de medidores de água com base em aprendizado profundo”. Em: **ADMIT '23: Anais da 2ª Conferência Internacional de Algoritmos, Mineração de Dados e Tecnologia da Informação**. ACM, nov. de 2023, pp. 27–33. DOI: 10.1145/3625403.3625409. URL: <https://doi.org/10.1145/3625403.3625409>.

Obrigado(a) pela Atenção!

Contato:

`anderson.oliveira@aluno.ufrb.edu.br`

`barbarans@aluno.ufrb.edu.br`

`jeovanessantos@aluno.ufrb.edu.br`

`queleandrade@aluno.ufrb.edu.br`

`ricardoteixeirasantos@aluno.ufrb.edu.br`