

# Regressão com Dados de Medidor de Água

Subtítulo da Apresentação

## Trabalho de Conclusão de Curso

**Estudante:** Erik Montgomery, Guilherme Pereira João Alves, Lucas Raphael, Marcos Vinicyus, Vinicius Silvestre, Yuri Lima

**Orientadores:** Prof. DR. Tiago Palma Pagano

**Curso:** Bacharelado em Engenharia de Computação

17 de dezembro de 2024

# Sumário

## 1 Resumo

## 2 Introdução

- Contextualização
- Justificativa
- Objetivo

## 3 DATASET

## 4 Metodologia

## 5 Resultados esperados

- Resultados esperados

## 6 Resultados Parciais

- Resultados Parciais

# Resumo

Esta apresentação explora o uso de técnicas de regressão para recuperar valores de medidores de água a partir de imagens. O processo envolveu a extração e interpretação dos números registrados nos mostradores, desde o tratamento das imagens até a aplicação da regressão para estimar os valores.

Serão apresentados os desafios enfrentados, as soluções adotadas e os resultados obtidos, demonstrando a eficiência da abordagem na recuperação precisa dos dados.

**Palavras-Chave:** Regressão, Análise de Dados, Consumo de Água, Modelagem Preditiva.

# Contextualização

Este trabalho aplica técnicas de Inteligência Artificial, especificamente regressão, para recuperar valores de medidores de água a partir de imagens. A solução automatiza a extração de dados, reduzindo erros humanos e demonstrando a aplicabilidade da IA na gestão eficiente de recursos essenciais.

# Justificativa

A leitura manual de medidores de água é suscetível a erros e demanda tempo. Este trabalho justifica-se pela necessidade de automação desse processo, utilizando técnicas de Inteligência Artificial para garantir maior precisão e eficiência na recuperação dos dados. Além disso, demonstra o potencial da IA para resolver problemas práticos e contribuir para a gestão otimizada de recursos essenciais.

# Objetivo

O objetivo deste trabalho é analisar os dados de medidores de água utilizando técnicas de regressão, com o intuito de recuperar os valores registrados a partir de imagens e avaliar a eficácia do modelo na automação desse processo.

# Water Meters Dataset, 1244 Photos Masks

O conjunto de dados contém uma coleção diversificada de imagens de hidrômetros, juntamente com máscaras de segmentação correspondentes e rótulos OCR para as leituras do medidor.

# Exemplo do dado

Figura: Exemplo DATASET kaggle



```
{
  "value": 0.521,
  "location": {
    "p1": {
      "x": 0.12,
      "y": 0.11
    },
    "p2": {
      "x": 0.82,
      "y": 0.11
    },
    "p3": {
      "x": 0.82,
      "y": 0.23
    },
    "p4": {
      "x": 0.12,
      "y": 0.23
    }
  }
}
```

Fonte: Kaggle.



# Exemplo do dado

Figura: Exemplo Hidrômetro



# Exemplo do dado

Figura: Exemplo Aplicado Máscara



# Exemplo do dado

Figura: Exemplo Máscara com Reshape



Fonte: Kaggle.

# Metodologia

Neste trabalho, utilizamos técnicas de visão computacional e aprendizado de máquina para desenvolver um modelo de regressão linear aplicado à leitura automática de relógios d'água. A metodologia pode ser dividida em quatro etapas principais: coleta e preparação dos dados, pré-processamento das imagens, configuração e treinamento do modelo e análise dos resultados.

# Metodologia

As imagens coletadas passaram por pré-processamento, incluindo recorte para isolar o mostrador e redimensionamento para 224x224 pixels, compatível com o modelo pré-treinado ResNet50. Optamos por não realizar normalização dos dados, pois testes iniciais não indicaram impacto significativo nos resultados, o que pode ser atribuído à capacidade interna do modelo de lidar com variações de escala.

# Metodologia

O ResNet50 foi empregado como base para extração de características, com adaptação de sua última camada para prever valores numéricos utilizando uma saída linear. O treinamento foi conduzido com divisão em conjuntos de treino, validação e teste, sendo avaliado por métricas como erro médio absoluto (MAE). Essa abordagem buscou aliar simplicidade no processo de pré-processamento à robustez do modelo, garantindo precisão nas previsões de consumo de água.

# Resultados esperados

Os resultados esperados para um modelo que prediz valores em um hidrômetro incluem alta precisão nas previsões, minimizando erros como MAE ou RMSE, e detecção de anomalias, como vazamentos ou consumo irregular.

O modelo deve se adaptar a diferentes perfis de consumo (Residencial, Comercial e Industrial) com eficiência computacional, permitindo uso em sistemas em tempo real e dispositivos de baixo custo. Além de reduzir custos operacionais ao substituir leituras manuais, espera-se que o modelo forneça previsões de tendências de consumo, auxiliando na gestão eficiente dos recursos hídricos.

# Resultados Parciais



Após a realização de testes exaustivos, não foi possível alcançar resultados satisfatórios. Diversas abordagens foram aplicadas, envolvendo ajustes de parâmetros, otimizações e variações nos métodos utilizados, contudo, os resultados obtidos permaneceram aquém do esperado.

As tentativas de aprimoramento não resultaram em melhorias significativas, evidenciando a necessidade de uma análise mais aprofundada das limitações enfrentadas e da possível reformulação da estratégia adotada.




# Resultados Parciais

Figura: MAE e MSE de Treino do Modelo




# Resultados Parciais

Figura: Predict do Modelo com dados do Treino



# Resultados Parciais


Figura: Predict do Modelo com dados de Teste




# Resultados Parciais

Figura: Predict do Modelo com dados de Teste

Crop da Imagem

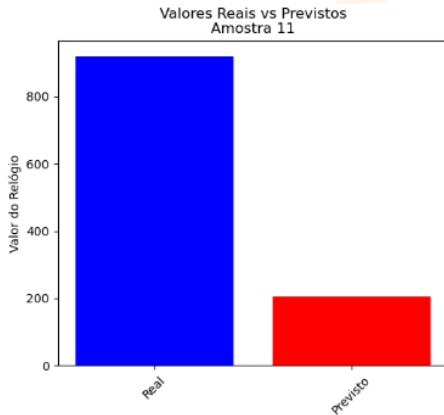



Valores Reais vs Previstos  
Amostra 19



# Resultados Parciais

Figura: Predict do Modelo com dados de Teste



# Obrigado(a) pela Atenção!

